

Sistema de Reconocimiento de Actividad Humana usando Puntos de Referencia de la Postura MediaPipe y Clasificación en Bosques Aleatorios

Juliana Filigrana Valencia
Facultad Barberi de Ingeniería, Diseño y
Ciencias Aplicadas
Universidad Icesi
Cali, Colombia
1107842545@u.icesi.edu.co

Angela María González Córdoba Facultad
Barberi de Ingeniería, Diseño y Ciencias
Aplicadas Universidad Icesi Cali, Colombia
angela.gonzalezcordoba@u.icesi.edu.co

Juan Manuel Casanova Marin Facultad
Barberi de Ingeniería, Diseño y Ciencias
Aplicadas Universidad Icesi Cali, Colombia
juan.casanovamarin@u.icesi.edu.co

Resumen— Este trabajo presenta un sistema de reconocimiento de actividad humana en tiempo real utilizando puntos de referencia de poses MediaPipe y aprendizaje supervisado. Se clasificaron cinco actividades: caminar hacia adelante, caminar hacia atrás, girar, sentarse y levantarse. Se recopiló un conjunto de datos de 15.656 fotogramas de 18 videos bajo condiciones controladas. MediaPipe extrajo 33 keypoints 3D del cuerpo, generando 1.629 características. La importancia de las características en el Bosque Aleatorio redujo la dimensionalidad a 100 características (reducción del 93,9%). La validación estratificada por grupos evitó la fuga temporal de datos, revelando una precisión realista del 80,4% frente al 99,8% ingenuo de la división aleatoria. La validación cruzada confirmó un 80,3% $\pm$ un 3,9% de generalización. El sistema alcanza 26 FPS en CPU de portátil, demostrando viabilidad práctica. El análisis reveló que "estar de pie" es el más desafiante ($F1=0,42$), frecuentemente confundido con "sentado" debido a la similitud biomecánica. Este trabajo valida el reconocimiento accesible y libre de marcadores de actividades para aplicaciones de cuidado de ancianos, rehabilitación e interacción humano-ordenador.

Palabras clave: Reconocimiento de Actividad Humana, Estimación de Pose, MediaPipe, Bosque Aleatorio, Introducción a la Selección de Características (Encabezado 1).

I. INTRODUCCIÓN

A. Context

El Reconocimiento de la Actividad Humana (HAR) permite aplicaciones en monitorización sanitaria, evaluación de rehabilitación y tecnologías de asistencia. Los enfoques tradicionales requerían sensores portátiles o equipos especializados de captura de movimiento, limitando la accesibilidad. La postura MediaPipe de Google [1] permite el seguimiento esquelético en tiempo real usando cámaras RGB estándar, democratizando el HAR basado en poses para su despliegue en entornos domésticos y clínicos sin hardware especializado.

B. Descripción del problema

Este proyecto aborda la clasificación automática de cinco actividades humanas fundamentales: caminar hacia adelante (hacia la cámara), caminar hacia atrás (alejándose de la cámara), girar, sentarse y levantarse. Estas actividades representan patrones esenciales de movilidad para el cuidado de ancianos (evaluación del riesgo de caídas), rehabilitación física (seguimiento de la adherencia a la terapia) y aplicaciones de fitness (reconocimiento automatizado de ejercicios).

El reto técnico consiste en distinguir diferencias biomecánicas sutiles mientras se manejan la variabilidad en la velocidad de ejecución, los ángulos de cámara y las diferencias antropométricas entre sujetos. A diferencia de las acciones discretas (por ejemplo, el waveing), estas actividades se desarrollan sobre secuencias temporales con estados transicionales que crean ambigüedad para la clasificación a nivel de marco.

C. ¿Por qué interesante?

Este problema pone de manifiesto tres desafíos críticos en aprendizaje automático: (1) **Ingeniería de características:** Extraer características discriminativas de coordenadas de pose de alta dimensión, (2) **Rigor de validación:** Prevenir fugas temporales de datos que inflan métricas de rendimiento, (3) **Despliegue en tiempo real:** Equilibrar la complejidad del modelo con la velocidad de inferencia para un despliegue práctico en el borde sin aceleración de GPU.

II. TEORÍA

A. Arquitectura de la postura MediaPipe


MediaPipe Pose emplea una tubería de dos etapas. La Etapa 1 (BlazePose Detector) localiza la caja delimitadora de personas usando una CNN ligera. La Etapa 2 (Red de Regresión Histórica) predice 33 puntos de referencia corporales 3D, incluyendo cabeza, hombros, codos, muñecas, caderas, rodillas y tobillos. La arquitectura utiliza la columna vertebral

MobileNetV2 para mayor eficiencia, alcanzando >30 FPS en dispositivos móviles.

Cada punto de referencia genera:

- (x, y): coordenadas 2D normalizadas a dimensiones de trama [0,1]
- z: Profundidad en píxeles relativa al punto medio de la cadera
- visibilidad: Confianza en la detección [0,1]

Esta representación depende del punto de vista pero es computacionalmente eficiente en comparación con los métodos volumétricos 3D.



B. Bosque aleatorio para clasificación

Random Forest [2] construye un conjunto de árboles de decisión durante el entrenamiento, cada uno construido sobre una muestra bootstrap de datos con subconjuntos de características aleatorias. Para la clasificación, cada árbol vota por una clase, y la predicción final es el voto mayoritario. Esto reduce la varianza en comparación con árboles de decisión individuales, manteniendo la interpretabilidad mediante métricas de importancia de características.

La importancia de Gini cuantifica la contribución de características sumando la reducción de impurezas en todas las divisiones usando esa característica:

$$\text{Importancia}(X_j) = \sum[t \in \text{árboles}] \sum[s \in \text{Splits}] \Delta \text{Gini}(s)$$

donde se usa la característica X_j

Una mayor importancia indica que la característica mejora frecuentemente la separación de clases. Esto permite una selección de características de principios sin una evaluación exhaustiva de subconjuntos

C. Ingeniería de características para HAR basado en poses


Las coordenadas brutas de los puntos de referencia sufren de: (1) Varianza de traslación: La posición absoluta depende de la ubicación de la persona en el encuadre, (2) Varianza de escala: Las coordenadas varían según la distancia persona-cámara, (3) Varianza de rotación: La orientación de la cabeza afecta la posición de los puntos de referencia faciales...

- **Centrado:** Resta el punto medio de la cadera de todas las coordenadas
- **Escala:** Divide por el ancho de los hombros o la altura del torso
- **Características derivadas:** Calcular ángulos de articulación usando productos escalares vectoriales.

D. Fuga de datos en datos temporales

Los fotogramas de vídeo presentan correlación temporal: los fotogramas consecutivos ($\Delta t = 33$ ms) son casi idénticos. El `train_test_split` estándar asigna tramas aleatoriamente, causando fugas de datos cuando aparecen tramas del mismo vídeo tanto en el tren como en el conjunto de pruebas. El modelo básicamente ve muestras de prueba durante el entrenamiento (memorización, no generalización).

Solución: La división estratificada por grupos garantiza que todos los fotogramas de un vídeo permanezcan juntos en tren o prueba, nunca en ambos. Esto simula un despliegue realista: entrenamiento en algunos sujetos/vídeos, pruebas en imágenes completamente invisibles.



III. METODOLOGÍA

A. Recogida de datos

Tres sujetos (miembros del grupo, de 20 a 22 años) realizaron cinco actividades en un aula controlada con iluminación uniforme y fondo sencillo. Vídeos grabados con el smartphone en trípode (1080p, 30 FPS, distancia de 3-4 m, vista frontal). Cada sujeto realizaba entre 3 y 5 repeticiones por actividad...

Protocolo:

- Caminar frente: Caminar hacia la cámara a ritmo normal (3-5 seg)
- Caminar espalda: Camina hacia atrás, alejándose de la cámara
- Girar: giro de 180° en el sitio (mezclado en sentido horario/antihorario)
- Sentado: Siéntate en la silla desde la posición de pie
- Ponerse de pie: Levántate desde la posición sentada

Total: 18 vídeos, 10-23 segundos cada uno = 20.728 fotogramas en bruto. La anotación manual segmentaba los vídeos en rangos de fotogramas etiquetados por actividad. Tras excluir fotogramas con <30% de visibilidad de hitmark y segmentos de transición (etiquetas ambiguas), conjunto de datos final: **15.656** frames con etiquetas limpias.

Distribución de clases:

- caminar_frente: 4.260 fotogramas (27%)
- GIRAR: 3.700 (24%)
- caminar_espalda: 2.946 (19%)
- sentado: 2.790 (18%)
- ponerse_de_pie: 1.960 (13%)

B. Extracción de características

MediaPipe Pose v0.10 procesaba cada fotograma con umbrales predeterminados (detection_conf=0,5, tracking_conf=0,5). Salida: 33 puntos de referencia × 3 coordenadas = 99 elementos base por fotograma.

Características derivadas:

1. Geométrico (12 ángulos): Flexión de rodilla, flexión de codo, ángulo de cadera, ángulo de hombro calculados mediante productos escalares vectoriales
2. Proporcional (3): Ancho de hombros, ancho de cadera, altura del torso
3. Temporal (99×2): Velocidades de primer orden ($\Delta\text{posición}/\Delta\text{tiempo}$) y aceleraciones de segundo orden ($\Delta\text{velocidad}/\Delta\text{tiempo}$) para todos los hitos

Normalización:

- Centra todas las coordenadas en el punto medio de la cadera
- Escala por ancho de hombro
- Manejar valores faltantes (MediaPipe no detecta algunos puntos de referencia debido a la oclusión) con imputación mediana

Espacio total de características: 1.629 características (99 en bruto + derivadas)

C. Selección de características

Problema: La alta dimensionalidad (muestras/características = 15.656/1.629 = 9,6:1) corre el riesgo de sobreajuste.

Enfoque 1 - Importancia de los Gini en el Bosque Aleatorio:

1. Entrena Random Forest (200 árboles) en las 1.629 características
2. Características de rango por importancia acumulada de los Gini
3. Selecciona las 100 mejores características (capturando un ~85% de importancia total)

Enfoque 2 - PCA (comparativo): PCA aplicada manteniendo una varianza del 95% → solo se necesitaban 7 componentes, confirmando una redundancia masiva. Sin embargo, los componentes de la ACP carecen de interpretabilidad (combinaciones lineales de muchos puntos de referencia).

Decisión: Usar Random Forest top-100 para el despliegue (mantiene la semántica de características, permite interpretar qué partes del cuerpo controlan la clasificación).

Características top 5:

1. landmark_15_x (ojo derecho horizontal)
2. landmark_349_z (profundidad de la cara)
3. landmark_17_x (ojo izquierdo horizontal)
4. landmark_14_x (oreja derecha horizontal)
5. landmark_2_y (punto medio entre ojos vertical)

Los puntos de referencia faciales predominan debido a los cambios de orientación de la cabeza durante las actividades.

D. División Tren/Prueba

Decisión crítica: Prevenir fugas temporales de datos usando GroupShuffleSplit(test_size=0.2, groups=video_ids). Esto garantiza que todos los fotogramas de un vídeo se mantengan juntos en la prueba de tren O sin mezclarse.

Resultado:

- Tren: 11.620 muestras de 14 vídeos (74%)
- Prueba: 4.036 muestras de 4 vídeos (26%)
- Vídeos de prueba: Vídeo 1, 10, 14, 17 (completamente invisible durante el entrenamiento)

E. Formación en modelos


Configuración de Random Forest (optimizada mediante GridSearchCV):

- n_estimators: 300 árboles
- max_depth: 30 (evitar sobreajuste de profundidad infinita)
- min_samples_split: 5
- min_samples_leaf: 2
- max_features: 'sqrt' ($\sqrt{100} \approx 10$ características por división, decora árboles)

- class weight: 'equilibrado' (compensa un ligero desequilibrio de clases)
-

Tiempo de entrenamiento: 34 segundos en Google Colab (CPU de 2 núcleos, 12GB de RAM)

Validación: Validación cruzada de GroupKFold de 5 ples, asegurando que no aparezca vídeo en múltiples pliegues.



IV. RESULTADOS

A. Impacto en la selección de características


Configuración	Funciones	Precisión de las pruebas	Inferencia (ms/marco)
Todas las características	1,629	80.8%	8.2
Top 100 RF	100	80.4%	3.2
PCA (95% variación)	7	76.2%	2.1

El top-100 de Random Forest logra un equilibrio óptimo: pérdida de precisión del 0,4%, inferencia un 61% más rápida, preserva la interpretabilidad.

B. Rendimiento del modelo

Modelo	Precisión de las pruebas	F1 (lastrado)	Tiempo de entrenamiento
Bosque Aleatorio	80.4%	0.792	34s
SVM (núcleo RBF)	75.3%	0.741	127s
MLP (64 unidades ocultas)	78.1%	0.768	Años 98

Bosque Aleatorio seleccionado para el despliegue: máxima precisión, inferencia más rápida (3,2 ms/fotograma → 26 FPS en tiempo real).



C. Validación cruzada (GroupKFold)

Doblar	Videos de prueba	Muestras	Exactitud
1	17, 5, 7	3,120	86.9%
2	10, 16, 3	2,987	75.7%
3	1, 13, 15	3,245	78.9%
4	11, 18, 6	3,088	81.7%
5	12, 14, 8	3,216	78.1%

Media ± edad: 80,3% ± 3,9%


La consistencia entre pliegues ($\sigma=3,9\%$) confirma una generalización robusta. Fold 2 (75,7%) es el más bajo debido a transiciones difíciles en Video 10.

D. Métricas por clase

Actividad	Precisión	Recordar	F1-Score	Apoyo
caminar_espalda	0.829	0.959	0.889	726
caminar_frente	0.895	0.888	0.891	998
girar	0.859	0.794	0.825	970
ponerse_de_pie	0.578	0.335	0.424	574
sentado	0.716	0.912	0.802	768
Media ponderada	0.795	0.804	0.792	4,036

Mejor: "caminar_frente" (F1=0,891)
Peor: "ponerse_de_pie" (F1=0,424, recordación=33,5%)

E. Confusión Matriz



Principales confusiones:

- ponerse_de_pie → sentado: 274/574 (47,7%) - similitud en la transición
- GIRAR → caminar_espalda: 144/970 (14,8%) - la rotación incluye pasos hacia atrás
- caminar_frente → ponerse_de_pie: 62/998 (6,2%) - el movimiento de pie se asemeja a la inclinación hacia adelante

F. Análisis de Generalización

Métrico	Tren	Prueba	Hueco
Exactitud	100.0%	80.4%	19.6%
F1-Score	1.000	0.792	20.8%


Un 19,6% de diferencia entre el tren y la prueba indica un **sobreajuste moderado**. Random Forest encaja perfectamente con los datos de entrenamiento (300 árboles, max_depth=30 permite límites complejos) pero se generaliza razonablemente a vídeos no vistos.

Comparación con la línea base (Entrega 2)

Método	Validación	Exactitud	Notas
Entrega 2	train_test_split (aleatorio)	99.8%	Fuga de datos
Entrega 3	GroupShuffleSplit (estratificado por vídeo)	80.4%	Realista

Método	Validación	Exactitud	Notas
Entrega 3	GroupKFold CV	80,3% ± 3,9%	Validado

El 99,8% original fue inflado artificialmente por correlación temporal entre trenes/fotogramas de prueba de los mismos vídeos. El rendimiento real es ~80%.



V. ANÁLISIS DE RESULTADOS

A. ¿Qué funciona bien

Discriminación al caminar hacia adelante/atrás (F1 ~0,89): A pesar de las sutiles diferencias en la marcha, el modelo distingue de forma fiable las direcciones. Características clave: patrones de trayectoria del tobillo (hacia adelante = talón de golpe, hacia atrás = empuje de dedos del pie), coordenada z de cadera (cambios de profundidad), desplazamientos faciales (orientación de la cabeza).

Detección de sentado (recuerdo=91,2%): Postura estática con baja altura de cadera + ángulos de rodilla grandes (>90°) proporciona una fuerte señal discriminativa. Un alto recuerdo indica pocos falsos negativos (rara vez se pierde la actividad sentada).

Rendimiento en tiempo real: 26 FPS en una CPU Intel i5 sin GPU demuestra la viabilidad del despliegue. El cuello de botella de inferencia es la detección de poses de MediaPipe (28 ms), no la predicción de Bosque Aleatorio (3 ms).

B. Lo que está fallando

Reconocimiento de pie (recuerdo=33,5%): 47,7% de los fotogramas "ponerse_de_pie" clasificados erróneamente como "sentado". Causas raíz: (1) Ambigüedad de transición: los fotogramas intermedios comparten características tanto de sentado como de pie, (2) Desequilibrio de clase: solo 1.960 muestras frente a 4.260 para "caminar_frente" (54% menos de datos), (3) Clasificación a nivel de fotograma: el modelo ignora la información de secuencia temporal.

Confusión entre giro y retroceso (14,8%): Giro de 180° implica pasos hacia atrás, creando características superpuestas. Posible fijación: añadir características de velocidad rotacional ($\Delta \text{shoulder_orientation} / \Delta t$) para distinguir la rotación pura de la traslación.

C. Evaluación de Generalización

Evidencia de sobreajuste:

- Precisión del tren 100% vs. prueba 80,4% (brecha del 19,6%)
- Validación cruzada STD 3,9% (varianza moderada entre pliegues)

Factores que contribuyen:

1. Diversidad limitada de conjuntos de datos (3 sujetos, 1 entorno)
2. Capacidad del modelo (300 árboles pueden memorizar patrones de entrenamiento)
3. Proporción muestras/características (9,6:1) por debajo del mínimo recomendado de 10:1

Mitigaciones (no implementadas):

- Reducir la complejidad del modelo (menos árboles, limitar aún más la profundidad)
- Aumento de datos (invertido horizontal, distorsión temporal)
- Regularización (aumento min_samples_leaf)

A pesar de la brecha, una precisión del 80,4% en las pruebas y resultados de CV consistentes demuestran una generalización razonable para la prueba de concepto.

D. Comparación con la literatura

Trabajo	Método	Actividades	Exactitud	¿Tiempo real?	Conjunto de datos
Kang et al. [3]	MediaPipe + LSTM	6	96.3%	No	3.000+ videos
Yan et al. [4]	ST-GCN (gráfico CNN)	60	81.5%	No (GPU)	56.880 muestras
Nuestro trabajo	MediaPipe + RF	5	80.4%	Sí (CPU)	15.656 fotogramas

Fortalezas: Ligero (sin GPU), importancia de características transparente, eficiente (reducción dimensional del 93,9%).

Debilidades: menor precisión que los enfoques de aprendizaje profundo, clasificación a nivel de trama que ignora la dinámica temporal, conjunto de datos limitado (3 sujetos frente a cientos en conjuntos de datos de referencia).

Nuestro 80,4% es competitivo para problemas de 5 clases con aprendizaje automático clásico, aunque los métodos profundos alcanzan mayor precisión en conjuntos de datos más grandes. Compensación: simplicidad e interpretabilidad frente a techo de rendimiento.

VI. CONCLUSIONES Y TRABAJOS FUTUROS

A. Lo que hicimos

Desarrollo de un sistema HAR de extremo a extremo: captura de vídeo → extracción de puntos de referencia MediaPipe → ingeniería de características → clasificación en bosques aleatorios → despliegue en tiempo real. Recogió 15.656 fotogramas anotados, redujo 1.629 características a 100 mediante la clasificación de importancia (reducción del 93,9%), alcanzó una precisión del 80,4% en las pruebas validadas mediante división estratificada por grupo y validación cruzada de 5 veces. Sistema desplegado que alcanza 26 FPS en CPU de portátil sin GPU.

B. Lo que hemos aprendido

Lecciones técnicas:

1. Rigor de validación crítico: La división adecuada estratificada por grupo reveló una inflación del 20% de precisión por fuga temporal de datos en la división ingenua
2. Selección de características efectiva: reducción dimensional del 93,9% con pérdida de precisión del <0,5% demuestra redundancia en coordenadas de pose en bruto
3. Interpretabilidad valiosa: La importancia de las características en Bosques Aleatorios identificó los puntos de referencia faciales y las coordenadas de cadera como los más discriminatorios, guiando la comprensión de las decisiones del modelo

Perspectivas prácticas:

1. **Un entorno controlado simplifica el problema:** Iluminación uniforme y fondo liso permitió la tasa de detección de poses del 100%
2. **Las actividades de transición más difíciles:** La confusión sentada↔de pie (48%) pone de manifiesto la necesidad de modelado de secuencias temporales
3. **Factible en tiempo real sin GPU:** La eficiencia de MediaPipe (detección de poses de 28 ms) permite el despliegue en el borde en hardware de consumo

C. Lo que se podría mejorar

Expansión del conjunto de datos:

- Aumentar los sujetos (3 → 50+) para diversidad demográfica (edad, tipo de cuerpo, etnia)
- Varía los entornos (exteriores, diferentes iluminaciones, fondos)
- Añadir escenarios de oclusión (visibilidad parcial del cuerpo)
- Clases de equilibrio (aumentar las muestras "ponerse_de_pie")

Mejoras de modelo:

- **Modelado temporal:** capas LSTM/GRU sobre secuencias emblemáticas para capturar dinámicas

de movimiento (dirección confusión sentado↔de pie)

- **Reducir el sobreajuste:** Recopilar más datos, disminuir la complejidad del modelo (menos árboles), aplicar regularización
- **Fusión multi-vista:** Combina cámaras frontal y lateral para entender el 3D

Actividades adicionales:

- Amplía el vocabulario: correr, saltar, agacharse, caer (detección de caídas para cuidado de ancianos)
- Detección de anomalías: señalización no supervisada de movimientos inusuales

Optimización del despliegue:

- Puerto móvil: TensorFlow Lite para Android/iOS (objetivo de latencia <50ms)
- Seguimiento multipersona: extender MediaPipe para detectar múltiples sujetos simultáneamente
- Explicabilidad: visualizar qué partes del cuerpo impulsan cada predicción (mapas de saliencia)

REFERENCIAS

- [1] V. Bazarevsky, I. Grishchenko, K. Raveendran, T. Zhu, F. Zhang y M. Grundmann, "BlazePose: Seguimiento de postura corporal en tiempo real en el dispositivo," arXiv preprint arXiv:2006.10204, 2020.
- [2] L. Breiman, "Random Forests," Machine Learning, vol. 45, n° 1, pp. 5-32, 2001.
- [3] M. Kang, J. Lee y W. Woo, "Reconocimiento de actividad humana usando MediaPipe y LSTM," Actas de la Conferencia Internacional IEEE sobre Electrónica de Consumo, pp. 1-4, 2020.
- [4] S. Yan, Y. Xiong y D. Lin, "Redes convolucionales de grafos espacio-temporales para el reconocimiento de acciones basadas en esqueletos," Actas de la Conferencia AAAI sobre Inteligencia Artificial, vol. 32, n° 1, 2018.
- [5] C. Lugaresi et al., "MediaPipe: Un marco para construir canalizaciones de percepción," arXiv preprint arXiv:1906.08172, 2019.
- [6] P. Chapman et al., "CRISP-DM 1.0: Guía de minería de datos paso a paso," SPSS Inc., 2000.
- [7] O. D. Lara y M. A. Labrador, "Un estudio sobre el reconocimiento de actividad humana usando sensores portátiles," IEEE Communications Surveys & Tutorials, vol. 15, n° 3, pp. 1192-1209, 2013.
- [8] R. Vemulapalli, F. Arrate y R. Chellappa, "Reconocimiento de la acción humana representando esqueletos 3D como puntos en un grupo de Lie," Actas del IEEE CVPR, pp. 588-595, 20